

Guía Digital sobre

LLM

Glosario y referencia rápida



Programa de formación profesional:
Integración estratégica de LLM como apoyo en la
gestión docente

Prof. Carmelo II Allende Martínez



Índice de términos

- Modelo de Lenguaje de Gran Tamaño (LLM)
- Arquitectura Transformer
- Alucinación (Hallucination)
- Sesgo Algorítmico
- Prompt (Instrucción)
- Ingeniería de Prompts (Prompt Engineering)
- Few-shot Learning
- Chain-of-Thought (Cadena de Pensamiento)
- Human in the Loop
- Fine-tuning
- Modelo Generativo vs. Discriminativo
- Tokenización

Modelo de Lenguaje de Gran Tamaño (LLM)

Definición:

Un LLM es un sistema de inteligencia artificial entrenado con enormes cantidades de texto para predecir la siguiente palabra más probable en una secuencia (Zhao et al., 2023). Estos modelos utilizan arquitecturas basadas en transformers y contienen millones o miles de millones de parámetros ajustables que les permiten generar respuestas coherentes, redactar textos, resumir, traducir y responder preguntas en lenguaje natural.

Ejemplos populares:

ChatGPT (OpenAI), Microsoft Copilot, Google Gemini, Claude (Anthropic).

Aplicación educativa:

Los LLM pueden proponer actividades y materiales, sugerir explicaciones alternativas, y redactar borradores de retroalimentación, siempre bajo la revisión crítica del docente (Damiano et al., 2024).

Arquitectura Transformer

Definición:

La arquitectura Transformer fue introducida por Vaswani et al. (2017) y "permite analizar relaciones entre palabras en distintos puntos de una oración o un texto extenso, capturando tanto significado como contexto" mediante mecanismos de auto-atención (self-attention).

Según Gillioz et al. (2020), los Transformers han revolucionado el campo del procesamiento del lenguaje natural al eliminar la necesidad de recurrencia y convolución, utilizando únicamente mecanismos de atención y capas feed-forward.

Por qué importa en educación:

Esta arquitectura permite que los LLM procesen textos largos (como ensayos estudiantiles o documentos curriculares completos) y capturen dependencias de largo alcance entre conceptos, lo que los hace útiles para análisis de textos, generación de retroalimentación detallada y adaptación de materiales.

Alucinación (Hallucination)

Definición:

La alucinación ocurre "cuando [el modelo] no tiene suficiente base factual o el prompt es ambiguo, [y] sigue produciendo la palabra 'más probable' según sus estadísticas, aunque el contenido no sea verdadero" (Russell & Norvig, 2020).

Chen et al. (2024) reformulan la alucinación como un fenómeno que debe ser entendido a lo largo del ciclo de vida del modelo, integrando tanto los mecanismos generativos como sus manifestaciones observables, destacando que no se trata solo de errores factuales, sino de outputs inesperados que pueden incluir inconsistencias o información no verificada.

Implicación para docentes:

Nunca asumir que lo que genera un LLM es correcto. El rol del docente como "experto validador" es esencial: debe cotejar datos, verificar fuentes y adaptar el contenido antes de usarlo con estudiantes.

Sesgo Algorítmico

Definición:

Los sesgos algorítmicos son distorsiones sistemáticas en las respuestas de un LLM que "pueden reflejar estereotipos de género, raza, idioma o contexto socioeconómico" presentes en los datos de entrenamiento (Russell & Norvig, 2020).

Manifestaciones en educación:

- Ejemplos que privilegian ciertas culturas o realidades
- Respuestas que minimizan experiencias de minorías
- Sugerencias de actividades no pertinentes al contexto local de Puerto Rico

Estrategia de mitigación:

Contrastar con fuentes diversas, adaptar al contexto del estudiantado y mantener uso crítico.

Prompt (Instrucción)

Definición:

Un prompt es la instrucción o pregunta en lenguaje natural que se le da a un LLM para guiar su respuesta. La calidad del prompt determina directamente la calidad del output.

Ejemplo básico:

"Actúa como maestro de 5to grado. Genera 3 problemas verbales de fracciones relacionados con deportes puertorriqueños."

Estructura recomendada:

Rol + Contexto + Tarea + Formato + Restricciones.

Ingeniería de Prompts (Prompt Engineering)

Definición:

La ingeniería de prompts es "el proceso de diseñar y refinar instrucciones efectivas para obtener resultados precisos, relevantes y útiles de un LLM" (adaptado de White et al., 2023).

Mejores prácticas documentadas:

- Especificar el rol que debe asumir el modelo
- Proporcionar contexto suficiente sobre el nivel, materia y objetivo
- Incluir ejemplos cuando sea necesario (few-shot)
- Solicitar formato específico (tabla, lista numerada, párrafo)
- Establecer restricciones éticas (no inventar datos, mantener tono apropiado)

Few-shot Learning

Definición:

Few-shot learning es una técnica donde se proporcionan al LLM algunos ejemplos del tipo de respuesta deseada antes de solicitar que genere una nueva instancia similar. Esto mejora la precisión y consistencia del output sin necesidad de reentrenar el modelo.

Ejemplo educativo:

text

Prompt: "Genera preguntas de comprensión lectora siguiendo este patrón:

Ejemplo 1: ¿Qué motivación tenía el personaje principal al inicio del cuento?

Ejemplo 2: ¿Cómo cambió la actitud del protagonista después del conflicto?

Ahora genera 3 preguntas similares para el texto [insertar texto]."

Chain-of-Thought (Cadena de Pensamiento)

Definición:

Chain-of-Thought (CoT) es una estrategia de prompting donde se solicita explícitamente al LLM que "muestre su razonamiento paso a paso" antes de dar la respuesta final. Wei et al. (2022) demostraron que cuando se pide al modelo que genere explicaciones paso a paso, no solo mejora la precisión de la respuesta, sino que proporciona un andamiaje didáctico.

Aplicación en matemáticas y ciencias:

En lugar de solo pedir "Resuelve: $3x + 5 = 20$ ", se formula:

"Resuelve $3x + 5 = 20$ explicando cada paso del proceso algebraico."

Human in the Loop

Definición:

"Human in the loop" es un principio de uso responsable de IA donde "la tecnología asume tareas de apoyo, pero la decisión final recae siempre en la persona profesional" (Alhalthli et al., 2025).

En educación, esto significa que el maestro:

- Usa el LLM para generar borradores
- Revisa cuidadosamente: exactitud factual, alineación curricular, pertinencia cultural
- Corrige, adapta o descarta según su criterio profesional

Por qué es crítico:

Esto preserva la centralidad del juicio docente, fortaleciendo su capital profesional (Hargreaves & Fullan, 2012), y reduce el riesgo de que 'salga del LLM' información no verificada o inapropiada para el contexto escolar.



Fine-tuning

Definición:

Fine-tuning es el proceso de ajustar un modelo pre-entrenado con datos específicos de un dominio o tarea particular para mejorar su desempeño en ese contexto específico.

Nota para docentes:

Como maestros cooperadores, no realizarán fine-tuning (es un proceso técnico avanzado), pero sí usarán modelos ya ajustados por las empresas desarrolladoras. Lo importante es saber que Microsoft Copilot está "fine-tuned" para integrarse con Office y ChatGPT puede tener versiones especializadas.

Modelo Generativo vs. Discriminativo

Definición:

- Modelo generativo (como los LLM): Genera nuevos contenidos (texto, imágenes) aprendiendo la distribución de probabilidad de los datos de entrenamiento.
- Modelo discriminativo: Clasifica o categoriza datos existentes (por ejemplo, detector de spam, clasificador de sentimientos).

Implicación práctica:

Los LLM son generativos, lo que significa que crean contenido nuevo combinando patrones aprendidos. Esto explica por qué pueden ser creativos pero también por qué pueden "inventar" información.

Tokenización

Definición:

La tokenización es el proceso de dividir el texto en unidades básicas (tokens) que el modelo puede procesar. Un token puede ser una palabra completa, parte de una palabra o un carácter.

Ejemplo:

La frase "Los estudiantes aprenden" podría tokenizarse como: ["Los", "estudiantes", "aprend", "en"]

Por qué importa:

Los LLM tienen límites de tokens (contexto máximo), lo que afecta cuánto texto pueden procesar de una vez. ChatGPT-4, por ejemplo, puede manejar ~8,000 tokens (~6,000 palabras aproximadamente).

Referencias

Alhalthi, M., Al-Ghadi, M., & Ramesh, A. (2025). Human-AI co-creation in engineering education: Leveraging ChatGPT-4 to develop authentic case studies. *Proceedings of the ACM Conference on Global Computing Education*. <https://doi.org/10.1145/3775073.3775080>

Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., ... & Amodei, D. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33, 1877-1901.

Chen, Y., Liu, Z., Zhang, Y., & Wang, X. (2024). Unified Hallucination Detection for Multimodal Large Language Models. *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 3235-3252. <https://aclanthology.org/2024.acl-long.178.pdf>

Damiano, A. D., Lauría, E. J., Sarmiento, C., & Zhao, N. (2024). Early Perceptions of Teaching and Learning Using Generative AI in Higher Education. *Journal of Educational Technology Systems*, 52(3), 346-375. <https://doi.org/10.1177/00472395241233290>

Gillioz, A., Casas, J., Mugellini, E., & Abou Khaled, O. (2020, September). Overview of the Transformer-based Models for NLP Tasks. In *2020 15th Conference on computer science and information systems (FedCSIS)* (pp. 179-183). IEEE.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30, 5998-6008.

Wei, J., Wang, X., Schuurmans, D., Bosma, M., Xia, F., Chi, E., ... & Zhou, D. (2022). Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems*, 35, 24824-24837.

White, J., Fu, Q., Hays, S., Sandborn, M., Olea, C., Gilbert, H., ... & Schmidt, D. C. (2023). A prompt pattern catalog to enhance prompt engineering with ChatGPT. *arXiv preprint arXiv:2302.11382*.

Zhao, W. X., Zhou, K., Li, J., Tang, T., Wang, X., Hou, Y., ... & Wen, J. R. (2023). A survey of large language models. *arXiv preprint arXiv:2303.18223*, 1(2).

Descubre más en www.xxxxxxx